DL_L5_CNNs Slaytındaki Matematiksel İşlemlerin İncelenmesi

Ad Soyad: Yeliz Nur Kılıç
Öğrenci No: 02220224049
Ders Adı: Derin Sinir Ağları

1. **Giriş:**
   Derin öğrenme, yapay sinir ağları kullanılarak verilerden öğrenme yapılmasını sağlayan bir makine öğrenmesi yöntemidir. Görüntü verilerinin analizinde yaygın olarak Convolutional Neural Networks kullanılmaktadır. CNN yapısında görüntüler üzerinde bazı matematiksel işlemler uygulanarak veriden anlamlı özellikler elde edilir. Bu işlemler sırasında kullanılan önemli parametrelerden bazıları stride ve padding değerleridir. Ayrıca sınıflandırma problemlerinde model çıktılarının olasılık değerlerine dönüştürülmesi için softmax fonksiyonu kullanılmaktadır.
2. **Stride ve Padding :**
   CNN mimarisinde convolution işlemi sırasında filtrelerin giriş verisi üzerinde nasıl hareket edeceğini belirleyen iki önemli parametre bulunmaktadır. Bunlar stride ve padding parametreleridir.
   Slaytta verilen örnekte aşağıdaki değerler bulunmaktadır:
   - Giriş boyutu: 5 × 5 × 3
   - Padding: 1
   - Stride: 2

   Burada giriş verisi üç kanallı bir görüntüyü temsil etmektedir. CNN işlemlerinde filtre giriş üzerinde kaydırılarak yeni bir feature map oluşturulur.

   2.1. Padding:
   Padding işlemi, giriş matrisinin etrafına sıfır değerleri eklenmesi işlemidir. Bunun amacı convolution işlemi sonucunda bilgi kaybını azaltmak ve çıktı boyutunu kontrol etmektir.
   Eğer giriş matrisi 5 × 5 ise ve padding değeri 1 seçilmişse, giriş matrisinin etrafına bir katman sıfır eklenir.
   Yeni boyut şu şekilde hesaplanır:
   Yeni giriş boyutu:

$$N_{new} = N + 2P$$

   Burada
   - N = giriş boyutu
   - P = padding

   Bu durumda:

$$N_{new} = 5 + 2(1) = 7$$

   Yani padding uygulandıktan sonra giriş matrisi **7 × 7** boyutuna çıkar.
   Padding sonucunun matriste gösterimi:

5 × 5 boyutunda matris mevcuttur buna 1 padding değeri uygulandığında matrisin etrafına 0 yanlızca bir katman kadar eklenir.

1 2 3 4 5
6 7 8 9 1
2 3 4 5 6
7 8 9 1 2
3 4 5 6 7

Padding=1 eklenince:

0 0 0 0 0 0 0
0 1 2 3 4 5 0
0 6 7 8 9 1 0
0 2 3 4 5 6 0
0 7 8 9 1 2 0
0 3 4 5 6 7 0
0 0 0 0 0 0 0

Yeni boyut:

$$5 + 2P = 5 + 2 = 7$$

Yani giriş artık **7×7 olur**.

2.2. Stride:

Stride, filtrenin giriş matrisi üzerinde her adımda kaç piksel ilerleyeceğini belirler. Stride değeri büyüdükçe filtre daha büyük adımlarla hareket eder ve oluşan özellik haritasının boyutu küçülür.

Çıktı Boyutunun Hesaplanması:

Convolution işlemi sonucunda elde edilen çıktı boyutu aşağıdaki formül ile hesaplanır:

$$Output = \frac{N - F + 2P}{S} + 1$$

Burada

- N = giriş boyutu
- F = filtre boyutu
- P = padding
- S = stride

Örneğin:

- Giriş = 5
- Filtre = 3
- Padding = 1
- Stride = 2

Formüle yerleştirirsek:

$$Output = \frac{5 - 3 + 2(1)}{2} + 1$$

Adım adım hesaplama:

$$5 - 3 = 2$$
$$2 + 2 = 4$$
$$4/2 = 2$$
$$2 + 1 = 3$$

Sonuç olarak elde edilen özellik haritası boyutu : 3×3 olmaktadır.

3. **Softmax Fonksiyonu:**

Softmax fonksiyonu, sınıflandırma problemlerinde kullanılan bir aktivasyon fonksiyonudur. Bu fonksiyon sinir ağı çıkışlarını olasılık değerlerine dönüştürür.
Softmax fonksiyonu sayesinde modelin her sınıfa ait olma olasılığı hesaplanır ve bu olasılıkların toplamı 1 olur.

Softmax Matematiksel Formülü:

Softmax fonksiyonu aşağıdaki şekilde tanımlanır:

$$P(y = i) = \frac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$$

Burada:

- z_i= i. sınıfa ait skor değeri
- K = toplam sınıf sayısı
- e= Euler sabiti

Softmax Örnek Hesaplama:

Bir sinir ağı çıktısı aşağıdaki gibi olsun:

$$z = [2.0,1.0,0.1]$$

Bu durumda üç farklı sınıf bulunmaktadır.
Adım 1: Üstel değerlerin hesaplanması

$$e^{2.0} = 7.389$$
$$e^{1.0} = 2.718$$
$$e^{0.1} = 1.105$$

Adım 2: Üstel değerlerin toplamı

$$7.389 + 2.718 + 1.105 = 11.212$$

Adım 3: Olasılıkların hesaplanması

Birinci sınıf:

$$7.389/11.212 = 0.659$$

İkinci sınıf:

$$2.718/11.212 = 0.242$$

Üçüncü sınıf:

$$1.105/11.212 = 0.099$$

Sonuç

Softmax fonksiyonu sayesinde model çıktıları olasılık dağılımına dönüştürülür. En yüksek olasılığa sahip sınıf, model tarafından tahmin edilen sınıf olarak seçilir.